AWB (Anwendungsbeobachtungen, Observational Studies)

This notebook reads in and cleans the received AWB data and shows some basic analysis.

In [1]:
```
from __future__ import division
import glob
from datetime import datetime, date, timedelta
import os
import itertools

import numpy as np
import matplotlib
import matplotlib.pyplot as plt
from pandas import DataFrame, Series
import pandas as pd

import seaborn as sns

%matplotlib inline
matplotlib.rcParams['svg.fonttype'] = 'none'

pd.options.display.max_rows = 150
```

In [2]:
```
filenames = [('data/AWB KBV Meldungen und Abschlüsse 2004 - 2011.xlsx', range(
2009, 2012)),
             ('data/AWB KBV Meldungen und Abschlüsse 2012 - 2014.xlsx', (2012,
2013, 2014))]


def read_excel(filename, years, kind='update', needle='Meldungen'):
    xl_file = pd.ExcelFile(filename)
    sheet_names = xl_file.sheet_names

    for year in years:
        sheet_name = [x for x in sheet_names if str(year) in x and needle in x
][0]
        print(filename, sheet_name)
        df = xl_file.parse(sheet_name)
        # Make index into row number column
        df = df.reset_index()
        df['year'] = year
        df['row_type'] = kind
        df = df.rename(columns=dict([(x, x.strip()) for x in df.columns if x.s
trip() != x]))
        # Consolidate column names
        df = df.rename(columns={u'Präparat': u'Präparatname',
                                u'Präparat/Titel der Anwendung': u'Präparatnam
e',
                                u'gemeldet am': 'DatumErstanzeige',
                                u'Datum Erstanzeige': 'DatumErstanzeige',
                                u'Beobachtugsplan vorliegend': 'Beobachtungspl
an vorliegend',
                                u'Ärzte gemeldet': u'gemeldete Ärzte',
                                u'Anzahl teilnehmende Ärzte (wenn angegeben)':
u'gemeldete Ärzte',
                                u'Anzahl der beobachtenden Ärzte': u'beobachte
nde Ärzte',
                                'index': 'row_number'
                               })
        if 'DatumErstanzeige' not in df.columns:
            df = df.rename(columns={'Eingang': 'DatumErstanzeige'})
        # Fix date columns
        date_cols = list(df.columns[df.columns.str.startswith('Datum')])
        for x in date_cols:
            df['dt_%s' % x] = pd.to_datetime(df[x], errors='coerce')
        df[u'Präparatname'] = df[u'Präparatname'].str.strip()
        # Remove entries with empty drug name
        df = df[df[u'Präparatname'].notnull()]
        yield df
```

First, read in all available update messages.

In [3]:
```
num_cols = ['Patienten geplant', 'Patienten beobachtet', u'gemeldete Ärzte', u
'beobachtende Ärzte',
            u'Vertragsärzte', u'Aufwandsentschädigung pro Patient']
float_cols = [u'Aufwandsentschädigung pro Patient']
```

In [4]:
```
df_updates = pd.concat(itertools.chain(*[read_excel(*args) for args in filenames]))

# To be compatible with Abschluesse column
df_updates['Aufwandsentschädigung gesamt in €'] = None

print('Number of rows', len(df_updates))
df_updates.head()
```

```
data/AWB KBV Meldungen und Abschlüsse 2004 - 2011.xlsx Meldungen 2009 Gesamt
data/AWB KBV Meldungen und Abschlüsse 2004 - 2011.xlsx Meldungen 2010 Gesamt
data/AWB KBV Meldungen und Abschlüsse 2004 - 2011.xlsx Meldungen 2011 Gesamt
data/AWB KBV Meldungen und Abschlüsse 2012 - 2014.xlsx 2012 Meldungen gesamt
data/AWB KBV Meldungen und Abschlüsse 2012 - 2014.xlsx 2013 Meldungen gesamt
data/AWB KBV Meldungen und Abschlüsse 2012 - 2014.xlsx 2014 Meldungen gesamt
Number of rows 13829
```

Out[4]:

	Art der NIS	Auftraggeber	Aufwandsentschädigung Kommentar	Aufwandsentschädigung pro Patient	Beobachtungsplan vorliegend	Beo
0	NaN	NaN	pro vollständig ausgefüllten Dokumentationsbog...	900	NaN	
1	NaN	NaN	pro vollständig dokumentierter Eingangsvisite,...	150	NaN	
2	NaN	NaN	Meldung vor Anzeigenpflicht	NaN	NaN	
3	NaN	NaN	Meldung vor Anzeigenpflicht	NaN	NaN	
4	NaN	NaN	NaN	20	NaN	

5 rows × 39 columns

In [5]:
```
# Catch bogus row that is way down and contains a different header
# Interesting colum "HonorarPlausibilität" (plausibility of fee) which is not
 available in our dataset
bad_series = df_updates[df_updates['Art der NIS'] == 'Art der NIS'].T.iloc[:,0
]
# Remove the row before processing further
df_updates = df_updates[~(df_updates['Art der NIS'] == 'Art der NIS')]
bad_series
```

Out[5]:

Art der NIS	Art der NIS
Auftraggeber	Auftraggeber
Aufwandsentschädigung Kommentar	Anzahl der Ärzte Gesamt
Aufwandsentschädigung pro Patient	AnzahlPatienten
Beobachtungsplan vorliegend	HonorarPlausibilität
BeobachtungszeitraumKommentar	BeobachtungszeitraumKommentar
Brief/Mail/Fax	DatumEingang
DatumAbmeldung	Meldungsart
DatumBrief	Brief/Mail/Fax
DatumEingang	ATC
DatumEnde	DatumEnde
DatumErstanzeige	DatumErstanzeige
DatumStart	DatumStart
Firma	Firma
Kommentar	NaN
MeldungsGrund	NaN
MeldungsKommentar	NaN
Meldungsart	DatumBrief
Meldungsinhalt	Meldezeitpunkt: Monat/Quartal/Jahr
Patienten beobachtet	Meldungsinhalt
Patienten geplant	NaN
Präparatname	Präparatname
Titel (Ziel)	Titel
Typ	Typ
Vertrag vorliegend	Honorar pro Patient
Vertragsärzte	NaN
Wirkstoff	Wirkstoff
beobachtende Ärzte	NaN
dt_DatumAbmeldung	NaT
dt_DatumBrief	NaT
dt_DatumEingang	NaT
dt_DatumEnde	NaT
dt_DatumErstanzeige	NaT
dt_DatumStart	NaT
gemeldete Ärzte	DatumAbmeldung
row_number	14947
row_type	update
year	2013
Aufwandsentschädigung gesamt in €	None

Name: 14947, dtype: object

Read in all final notices.

In [6]:
```
abschluesse_df = pd.concat(itertools.chain(*[read_excel(*args, needle='Abschl'
, kind='final') for args in filenames]))

abschluesse_df

# Make columns compatible with update notices
columns = u'dt_DatumErstanzeige dt_DatumStart   dt_DatumEingang Präparatname
Wirkstoff       Firma   Patienten beobachtet    Patienten geplant       beobac
htende Ärzte    gemeldete Ärzte Aufwandsentschädigung pro Patient       Aufwan
dsentschädigung Kommentar       Aufwandsentschädigung gesamt in €       Art de
r NIS   Auftraggeber    Beobachtungsplan vorliegend     BeobachtungszeitraumKo
mmentar Brief/Mail/Fax  DatumAbmeldung  DatumBrief      DatumEingang    DatumE
nde     Kommentar       MeldungsGrund   MeldungsKommentar       Meldungsart
Meldungsinhalt  Titel (Ziel)    Typ     Vertrag vorliegend      Vertragsärzte
dt_DatumAbmeldung       dt_DatumBrief   dt_DatumEnde    year'.split('\t')
for c in columns:
    if c not in abschluesse_df:
        abschluesse_df[c] = None

print('Number of rows', len(abschluesse_df))
abschluesse_df.head()
```

```
data/AWB KBV Meldungen und Abschlüsse 2004 - 2011.xlsx Abschlüsse 2009
data/AWB KBV Meldungen und Abschlüsse 2004 - 2011.xlsx Abschlüsse 2010
data/AWB KBV Meldungen und Abschlüsse 2004 - 2011.xlsx Abschlüsse 2011
data/AWB KBV Meldungen und Abschlüsse 2012 - 2014.xlsx 2012 Abschlüsse
data/AWB KBV Meldungen und Abschlüsse 2012 - 2014.xlsx 2013 Abschlüsse
data/AWB KBV Meldungen und Abschlüsse 2012 - 2014.xlsx 2014 Abschlüsse
Number of rows 365
```

Out[6]:

	Art der NIS	Auftraggeber	Aufwandsentschädigung Kommentar	Aufwandsentschädigung gesamt in €	Aufwandsentschädigung pro Patient
0	NaN	NaN	keine Aufwandsentschädigung angegeben	k.A.	NaN
1	NaN	NaN	pro Patient	97743.2	80
2	NaN	NaN	keine Aufwandsentschädigung angegeben	k.A.	NaN
3	NaN	Janssen-Cilag GmbH	pro dokumentierten Patienten	k.A.	75
4	NaN	NaN	pro Patient	k.A.	90

5 rows × 39 columns

In [7]:
```
# Same as before, remove bogus header row at line 12607 of final notices in ye
ar 2013
bad_series = abschluesse_df[abschluesse_df['Art der NIS'] == 'Art der NIS'].T.
iloc[:,0]
# Remove the row before processing further
abschluesse_df = abschluesse_df[~(abschluesse_df['Art der NIS'] == 'Art der NI
S')]
bad_series
```

Out[7]:
```
Art der NIS                                 Art der NIS
Auftraggeber                                Auftraggeber
Aufwandsentschädigung Kommentar             Anzahl der Ärzte Gesamt
Aufwandsentschädigung gesamt in €                      NaN
Aufwandsentschädigung pro Patient           AnzahlPatienten
Beobachtungsplan vorliegend                 HonorarPlausibilität
BeobachtungszeitraumKommentar               BeobachtungszeitraumKommentar
Brief/Mail/Fax                              DatumEingang
DatumAbmeldung                              Meldungsart
DatumBrief                                  Brief/Mail/Fax
DatumEingang                                       ATC
DatumEnde                                   DatumEnde
DatumErstanzeige                            DatumErstanzeige
DatumStart                                  DatumStart
Firma                                              Firma
Kommentar                                            NaN
MeldungsGrund                                        NaN
MeldungsKommentar                                    NaN
Meldungsart                                 DatumBrief
Meldungsinhalt                 Meldezeitpunkt: Monat/Quartal/Jahr
Patienten beobachtet                        Meldungsinhalt
Patienten geplant                                    NaN
Präparatname                                Präparatname
Titel (Ziel)                                       Titel
Typ                                                  Typ
Vertrag vorliegend                          Honorar pro Patient
Vertragsärzte                                        NaN
Wirkstoff                                   Wirkstoff
beobachtende Ärzte                                   NaN
dt_DatumAbmeldung                                    NaT
dt_DatumBrief                                        NaT
dt_DatumEingang                                      NaT
dt_DatumEnde                                         NaT
dt_DatumErstanzeige                                  NaT
dt_DatumStart                                        NaT
gemeldete Ärzte                             DatumAbmeldung
row_number                                         12605
row_type                                           final
year                                                2013
Name: 12605, dtype: object
```

Get cleaner number representation of total amount.

In [8]:
```
import re
import numbers

NUMBER_RE = re.compile('^\s*([\d\., ]+)')
NUMBERS_RE = {
    re.compile(r'^([\d\.]+),(\d{1,2}]+)'): '.',
    re.compile(r'^([\d,]+)\.(\d{1,2}]+)'): ',',
}

def clean_money(x):
    if isinstance(x, numbers.Number):
        return x
    x = NUMBER_RE.sub('\\1', x)
    for reg, repl in NUMBERS_RE.items():
        m = reg.search(x)
        if m is None:
            continue
        before = int(m.group(1).replace(repl, ''))
        after = int(m.group(2))
        if after < 10:
            after = after / 10.0
        else:
            after = after / 100.0
        return before + after
    return None

abschluesse_df['Aufwandsentschädigung gesamt'] = abschluesse_df['Aufwandsentschädigung gesamt in €'].apply(clean_money)
abschluesse_df[['Aufwandsentschädigung gesamt', 'Aufwandsentschädigung gesamt in €']].head()
```

Out[8]:

	Aufwandsentschädigung gesamt	Aufwandsentschädigung gesamt in €
0	NaN	k.A.
1	97743.2	97743.2
2	NaN	k.A.
3	NaN	k.A.
4	NaN	k.A.

In [9]:
```
grouper = ['dt_DatumErstanzeige', 'dt_DatumStart']

# Fill missing values in grouping columns with dummy value,
# so it's not silently dropped by pandas groupby
dummy_date = pd.to_datetime(date(1900, 1, 1))
abschluesse_df[grouper] = abschluesse_df[grouper].fillna(dummy_date)
df_updates[grouper] = df_updates[grouper].fillna(dummy_date)

assert not abschluesse_df[grouper].isnull().any().any()
assert not df_updates[grouper].isnull().any().any()
```

Combine update notices and final notices.

In [10]:
```
df_all = pd.concat([df_updates, abschluesse_df])
df_all = df_all.reset_index(drop=True)

df_all['row_type'].value_counts()
```

Out[10]:
```
update    13828
final       364
Name: row_type, dtype: int64
```

In [11]:
```
# Add simpler version of präparatname that might group better later

DRUG_NAME_SPLITTER = re.compile(r'[^\w ]|\d|_', re.U | re.I)

def clean_praeparat(praeparat):
    name = DRUG_NAME_SPLITTER.split(praeparat)[0].strip().lower()
    if len(name) < 4:
        return praeparat
    return name


df_all['praeparat'] = df_all[u'Präparatname'].apply(clean_praeparat)

print('Original Präparatname Number of Groups', len(df_all[u'Präparatname'].va
lue_counts()))
print('Cleaned Präparatname Number of Groups', len(df_all['praeparat'].value_c
ounts()))
```

```
Original Präparatname Number of Groups 997
Cleaned Präparatname Number of Groups 813
```

In [12]:
```
for name in num_cols:
    new_name = 'num_%s' % name
    df_all[new_name] = df_all[name].copy()
    df_all[new_name] = df_all[new_name].apply(str)

    if name not in float_cols:
        df_all[new_name] = (df_all[new_name]
                            .str.replace('(geplante Anzahl *:?|ca\.|max\.|geplant
 *:)', '', flags=re.I)
                            .str.strip()
                            .str.replace(r'[ ,\.]', '')
        )
    df_all[new_name] = (df_all[new_name]
                    .str.replace('^\d+-(\d+)$', '\\1')
    )
    if name not in float_cols:
        df_all[new_name] = (df_all[new_name]
            .str.replace(r'^(\d+).*', '\\1', flags=re.I)
        )
    df_all[new_name] = pd.to_numeric(df_all[new_name], errors='coerce')
```

In [40]:
```
# Check if cleaning kind of worked
df_all[df_all['Patienten geplant'].str.contains(' ').fillna(False)][['Patienten geplant', 'num_Patienten geplant']].sample(10)
```

Out[40]:

	Patienten geplant	num_Patienten geplant
8648	700 (500)	700
3807	25 Patienten	25
2981	36000, vorher 20000	36000
2584	23000 Patienten	23000
10036	584 (weltweit?)	584
5126	15 000	15000
991	36 000	36000
2430	1060 Patienten	1060
1888	14 000	14000
6488	ca. 300, erhöht auf 600	300

Analysis

Here's some exploratory analysis around the dataset.

First step is to group the single update and final notices into observational studies (AWB). We define the identification of one AWB to be the combination of its drug name, its registration date and its start date.

Per group of notices we find maxmimal numeric values for certain key figures and take the most prominent or last value for other columns.

In [14]:
```
def get_best_value(series):
    vc = series.value_counts()
    if len(vc) == 0:
        lvi = series.last_valid_index()
        if lvi is None:
            return None
        return series[lvi]
    return vc.idxmax()

def get_awbs(groups):

    for key, rows in groups:
        # Use maximum number across columns and rows for one AWB
        patient_count = rows[['num_Patienten beobachtet', 'num_Patienten gepla
nt']].max().max()
        doc_count = rows[['num_beobachtende Ärzte', 'num_gemeldete Ärzte']].ma
x().max()
        fee_per_patient = rows[[u'num_Aufwandsentschädigung pro Patient']].max
().max()

        yield pd.DataFrame([{
                'praeparat': key[0],
                'Präparatname': get_best_value(rows['Präparatname']),
                'dt_DatumErstanzeige': key[1],
                'dt_Start': key[2],
                'patient_count': patient_count,
                'doc_count': doc_count,
                'fee_per_patient': fee_per_patient,
                'calculated_total_fee': fee_per_patient * patient_count,
                'fee_comment': get_best_value(rows['Aufwandsentschädigung Komm
entar']),
                'final_total_fee': rows['Aufwandsentschädigung gesamt'].max(),
                # Use most used values across AWB rows
                'Auftraggeber': get_best_value(rows['Auftraggeber']),
                'Firma': get_best_value(rows['Firma']),
                'Wirkstoff': get_best_value(rows['Wirkstoff']),
                'dt_DatumEnde': get_best_value(rows['dt_DatumEnde']),
            }])


awb_grouper = ['praeparat', 'dt_DatumErstanzeige', 'dt_DatumStart']
groups = df_all.sort_values(['dt_DatumEingang']).groupby(awb_grouper)
df_awb = pd.concat(get_awbs(groups))
df_awb = df_awb.reset_index(drop=True)
df_awb.head()
```

Out[14]:

	Auftraggeber	Firma	Präparatname	Wirkstoff	calculated_total_fee	do
0	None	LA-SER Europe Ltd.	(diverse Antiarrhythmika)	kein spezieller Wirkstoff	500000	
1	Lilly Deutschland GmbH	ICON plc (CRO)	(diverse Präparate), Alimta	diverse Wirkstoffe	193200	
2	Novartis Pharma GmbH	Lungenforschung	, Ultibro	Glycopyrroniumbromid, Indacaterol	5040000	
3	Beiersdorf AG	GKM Gesellschaft für Therapieforschung mbH	ABC® Wärme-Pflaster Capsicum 11 mg	Dickextrakt aus Cayennepfeffer (4-7:1) entspre...	20000	
4	None	IAS Dr. Jörg Schnitker GmbH	ALK-depot SQ 200	gereinigte Allergene aus verschiedenen Pollen	162000	

Number of extracted AWBs

In [15]:
```
len(df_awb)
```

Out[15]:
```
1589
```

Numbers of patients

In [16]:
```
df_awb['patient_count'].sum()
```

Out[16]:
```
5270426.0
```

In [17]:
```
df_awb['patient_count'].describe()
```

Out[17]:
```
count       1120.000000
mean        4705.737500
std        51059.828867
min            0.000000
25%          200.000000
50%          500.000000
75%         1500.000000
max      1500000.000000
Name: patient_count, dtype: float64
```

Numbers of doctors

In [18]:
```
df_awb['doc_count'].sum()
```

Out[18]:
```
769844.0
```

In [19]:
```
df_awb['doc_count'].describe()
```

Out[19]:
```
count      868.000000
mean       886.917051
std       2615.096255
min          0.000000
25%         50.000000
50%        215.000000
75%        822.500000
max      61500.000000
Name: doc_count, dtype: float64
```

Fee per Patient

In [20]:
```
df_awb['fee_per_patient'].describe()
```

Out[20]:
```
count    1409.000000
mean      505.490823
std       686.699514
min         0.000000
25%       100.000000
50%       300.000000
75%       650.000000
max      7280.000000
Name: fee_per_patient, dtype: float64
```

In [21]:
```
df_awb['final_total_fee'].describe()
```

Out[21]:
```
count        120.000000
mean      217266.498133
std       537010.092590
min            0.000000
25%        14430.000000
50%        56212.500000
75%       185256.675000
max      4984295.000000
Name: final_total_fee, dtype: float64
```

How many AWBs over the years?

In [22]:
```
awbs_per_year = df_awb.groupby(df_awb.dt_DatumErstanzeige.dt.year).size()

# Drop stupid values
awbs_per_year = awbs_per_year.drop([1900, 1905])
awbs_per_year
```

Out[22]:
```
dt_DatumErstanzeige
2000      1
2001      1
2002      1
2003      5
2004      7
2005     19
2006     55
2007     71
2008    153
2009    245
2010    249
2011    202
2012    219
2013    156
2014    173
dtype: int64
```

In [23]:
```
awbs_per_year.plot()
```

Out[23]:
```
<matplotlib.axes._subplots.AxesSubplot at 0x10de3cb38>
```

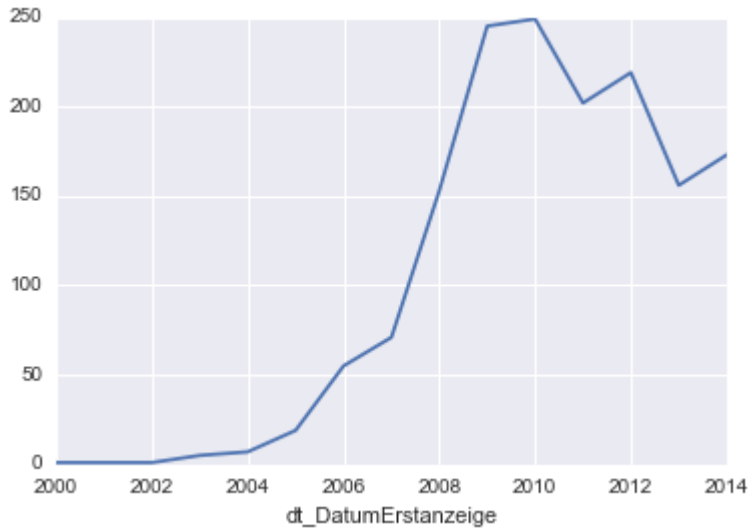

How many patients were in the studies over the years?

In [24]:
```
patients_per_year = df_awb.groupby(df_awb.dt_Start.dt.year)['patient_count'].sum()
patients_per_year
```

Out[24]:
```
dt_Start
1900      34978
1987        NaN
1993        NaN
1995       1000
1996        NaN
1999      36000
2000       3402
2001        400
2003         36
2004      52009
2005      14397
2006      33757
2007      45020
2008     216901
2009    1939378
2010     456893
2011    1365986
2012     494402
2013     442075
2014     133187
2015        605
Name: patient_count, dtype: float64
```

In [25]:
```
patients_per_year.plot(kind='bar')
```

Out[25]:
```
<matplotlib.axes._subplots.AxesSubplot at 0x10d5a2f28>
```

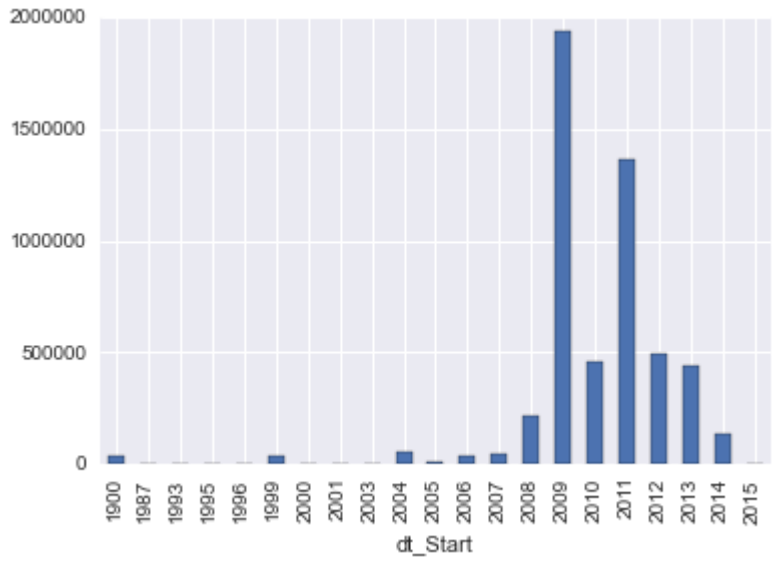

How many doctors participated over the years?

In [26]:
```
doctors_per_year = df_awb.groupby(df_awb.dt_Start.dt.year)['doc_count'].sum()
doctors_per_year
```

Out[26]:
```
dt_Start
1900     11385
1987      2020
1993      1240
1995       NaN
1996       NaN
1999      1380
2000       440
2001        10
2003       370
2004      1694
2005       241
2006     27014
2007     19940
2008     44914
2009    101600
2010    157077
2011    102957
2012    138402
2013     98724
2014     60236
2015       200
Name: doc_count, dtype: float64
```

In [27]:
```
doctors_per_year.plot(kind='bar')
```

Out[27]:
```
<matplotlib.axes._subplots.AxesSubplot at 0x10d587dd8>
```

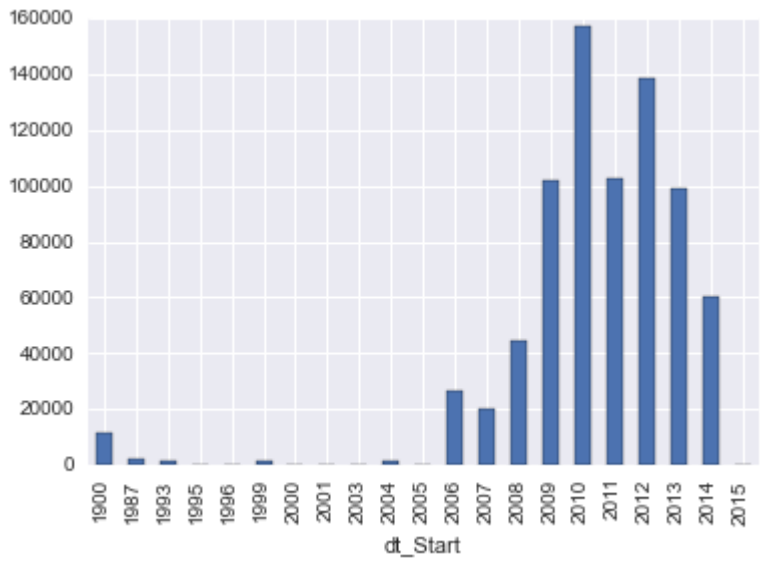

In [28]:
```
awbv = ['Auftraggeber', 'Firma', 'Präparatname', 'doc_count', 'patient_count',
'final_total_fee', 'fee_per_patient',
        'fee_comment', 'calculated_total_fee', 'praeparat', 'Wirkstoff', 'dt_D
atumEnde', 'dt_DatumErstanzeige',
        'dt_Start']
```

Highest patient count

In [29]:
```
df_awb.sort_values('patient_count', ascending=False).head(10)[awbv]
```

Out[29]:

	Auftraggeber	Firma	Präparatname	doc_count	patient_count	final_total_fee	fee_per_
1533	None	Guerbet GmbH	Xenetix 250/300/350	1830	1500000	1136800	
329	None	Guerbet GmbH	Dotarem	64	750000	450110	
1246	None	Daiichi Sankyo	Sevikar	NaN	153610	NaN	
826	None	Agfa HealthCare Imaging Agents GmbH	Magnegita	0	150000	NaN	
1248	Daiichi Sankyo Deutschland GmbH	INC Research, vorher Kendle GmbH	Sevikar HCT	18920	130000	525560	
947	CHDI Foundation, Inc.	Quintiles GmbH	nicht zutreffend	NaN	100000	NaN	
331	None	Guerbet GmbH	Dotarem	150	100000	30480	
69	Chiesi Farmaceutici S.p.A.	Pierrel Research	alle zugelassenen Anti-Asthma Therapien	240	81500	NaN	
1249	Daiichi Sankyo Deutschland GmbH	CFC - Stolberg	Sevikar HCT	1436	65000	447500	
351	None	Takeda Pharma GmbH	Edarbi	4380	50000	409550	

Highest fee per patient

In [30]:
```
df_awb.sort_values('fee_per_patient', ascending=False).head(10)[awbv]
```

Out[30]:

	Auftraggeber	Firma	Präparatname	doc_count	patient_count	final_total_fee
253	Merck Serono SA-Geneva	Outcome Europe Sarl (CRO)	Cladribine	NaN	2000	NaN
66	Pfizer Pharma GmbH	Parexel International GmbH	alle mit Latanoprost sowie nicht-Latanoprost-h...	10	14	NaN
928	Schwarz Pharma Deutschland GmbH	UCB Biosciences GmbH	Neupro transdermales Pflaster	100	NaN	NaN
1384	Pfizer Pharma GmbH	Winicker Norimed GmbH	Torisel, Sutent, Inlyta	1890	1600	NaN
626	None	AbbVie Deutschland GmbH & Co. KG	HUMIRA	110	NaN	NaN
625	None	Abbott GmbH & Co. KG	Humira	NaN	NaN	NaN
942	Chiesi	CROMSOURCE GmbH	nicht-medikamentöse Beobachtungsstudie	30	89	NaN
645	Alimera Sciences Limited	medicomp	Iluvien	80	800	NaN
636	Baxter Innovations GmbH/Wien	Baxter Innovations GmbH/Wien	HyQvia	110	42	NaN
239	Baxter Healthcare	Dabio (MAPI S.A.S)	Ceprotin	60	40	NaN

Highest calculated total fee (fee per patient times number of patients)

In [31]:
```
df_awb.sort_values('calculated_total_fee', ascending=False).head(10)[awbv]
```

Out[31]:

	Auftraggeber	Firma	Präparatname	doc_count	patient_count	final_total_fee	fee_
947	CHDI Foundation, Inc.	Quintiles GmbH	nicht zutreffend	NaN	100000	NaN	
804	Novartis Pharma GmbH	clinicalmonitor (Quintiles)	Lucentis	200	30000	NaN	
805	None	Novartis Pharma GmbH	Lucentis	210	30000	NaN	
809	Novartis Pharma GmbH	Kantar Health GmbH	Lucentis	NaN	20000	NaN	
1069	None	Roche Pharma AG	Pegasys	6000	9790	NaN	
69	Chiesi Farmaceutici S.p.A.	Pierrel Research	alle zugelassenen Anti-Asthma Therapien	240	81500	NaN	
999	Thrombosis Research Institute (UK)	Parexel International GmbH	orale + andere Antikoagulanzien	NaN	50000	NaN	
1533	None	Guerbet GmbH	Xenetix 250/300/350	1830	1500000	1136800	
943	Thrombosis Research Institute (UK)	Parexel International GmbH	nicht zutreffend	NaN	50000	NaN	
253	Merck Serono SA-Geneva	Outcome Europe Sarl (CRO)	Cladribine	NaN	2000	NaN	

Highest total final costs per AWB

In [32]:
```
df_awb.sort_values('final_total_fee', ascending=False).head(10)[awbv]
```

Out[32]:

	Auftraggeber	Firma	Präparatname	doc_count	patient_count	final_total_fee	fee_per
611	None	Abbott GmbH & Co. KG	HUMIRA 40 mg	3510	5000	4984295.00	
101	None	AMGEN GmbH	Aranesp	620	950	2016638.00	
1352	None	Sanofi-Aventis Deutschland GmbH	Taxotere	4530	40000	1425312.75	
203	None	Roche Pharma AG	Bonviva , Fosamax , diverse Alendronat-Generika	2000	6009	1299733.75	
1533	None	Guerbet GmbH	Xenetix 250/300/350	1830	1500000	1136800.00	
814	None	Roche Pharma AG	MabThera	2160	5330	1073488.20	
1517	Shire Deutschland GmbH & Co. KG	POI Pharm-Olam International Deutschland GmbH	Xagrid	190	3647	790058.51	
868	None	Roche Pharma AG	Mircera	350	1500	678961.71	
259	None	Sanofi-Aventis Deutschland GmbH	Clexane 20 mg, 40 mg, 100 mg	530	816	614823.50	
176	CSL Behring GmbH	Chiltern International Ltd.	Berinert	5	113	600129.62	

MabThera AWB

In [33]:
```
v = ['dt_DatumEingang', 'Präparatname', 'Auftraggeber', 'Patienten beobachtet'
, 'Patienten geplant',
     'Aufwandsentschädigung pro Patient', 'Aufwandsentschädigung gesamt in €',
'row_type', 'year', 'row_number']
df_all[(df_all['Präparatname'] == 'MabThera') & (df_all['dt_DatumErstanzeige']
.dt.year == 2009) & (df_all['dt_DatumErstanzeige'].dt.month == 5)][v]
```

Out[33]:

	dt_DatumEingang	Präparatname	Auftraggeber	Patienten beobachtet	Patienten geplant	Aufwandsentschädi pro P
960	2009-06-08	MabThera	NaN	NaN	NaN	
1159	2009-07-10	MabThera	NaN	NaN	NaN	
1346	2009-08-17	MabThera	NaN	NaN	NaN	
3603	2010-08-16	MabThera	NaN	NaN	NaN	
3864	2010-09-30	MabThera	NaN	229	NaN	
13879	2010-09-30	MabThera	NaN	229	NaN	

In [34]:
```
df_awb[df_awb['Präparatname'] == 'MabThera'][awbv]
```

Out[34]:

	Auftraggeber	Firma	Präparatname	doc_count	patient_count	final_total_fee	fee_per_
814	None	Roche Pharma AG	MabThera	2160	5330	1073488.2	
815	None	Roche Pharma AG	MabThera	460	229	65742.5	
816	Roche Pharma AG	proinnovera	MabThera	1380	NaN	NaN	
817	None	Roche Pharma AG	MabThera	NaN	NaN	NaN	
818	None	Roche Pharma AG	MabThera	90	NaN	NaN	
819	None	Roche Pharma AG	MabThera	NaN	NaN	NaN	
820	None	Roche Pharma AG	MabThera	2640	NaN	NaN	
822	None	Roche Pharma AG	MabThera	100	700	NaN	
823	Roche Pharma AG	AMS Advanced Medical Services GmbH	MabThera	1390	1076	NaN	

Difference between calculated total fee and final total fee

Top 10 where final total is higher than calculated total costs.

In [42]:
```
df_awb['final_calculated_diff'] = df_awb['calculated_total_fee'] - df_awb['final_total_fee']
df_awb.sort_values('final_calculated_diff').head(10)[['final_calculated_diff'] + awbv]
```

Out[42]:

	final_calculated_diff	Auftraggeber	Firma	Präparatname	doc_count	patient_co
611	-4234295.00	None	Abbott GmbH & Co. KG	HUMIRA 40 mg	3510	5(
1352	-825312.75	None	Sanofi-Aventis Deutschland GmbH	Taxotere	4530	40(
176	-534589.62	CSL Behring GmbH	Chiltern International Ltd.	Berinert	5	
1350	-186760.50	None	Sanofi-Aventis Deutschland GmbH	Taxotere 20mg/80mg Infusionslösung (Arzneimittel)	1450	4
865	-20196.63	None	Roche Pharma AG	Mircera	400	3
200	-10720.50	None	Takeda Pharma GmbH	Blopress forte 32 mg Plus 25	10110	4(
170	-9156.00	GlaxoSmithKline	Kantar Health GmbH	Benlysta	210	1
1560	-8950.00	None	Actelion Pharmaceuticals Deutschland GmbH	Zavesca 100 mg Hartkapseln (Arzneimittel)	70	
815	-8492.50	None	Roche Pharma AG	MabThera	460	2
821	-7400.00	None	Roche Pharma AG	MabThera, Enbrel, Humira, Remicade	14	

Top 10 where final total is lower than calculated total costs.

In [43]:
```
df_awb.sort_values('final_calculated_diff', ascending=False).head(10)[['final_calculated_diff'] + awbv]
```

Out[43]:

	final_calculated_diff	Auftraggeber	Firma	Präparatname	doc_count	patient_
1533	13863200.00	None	Guerbet GmbH	Xenetix 250/300/350	1830	15
926	13463449.87	UCB Pharma GmbH	PRA: Pharmaceutical Research Associates GmbH	Neupro	450	
1517	12878897.49	Shire Deutschland GmbH & Co. KG	POI Pharm-Olam International Deutschland GmbH	Xagrid	190	
1248	11174440.00	Daiichi Sankyo Deutschland GmbH	INC Research, vorher Kendle GmbH	Sevikar HCT	18920	1
777	7873880.00	None	Sanofi-Aventis Deutschland GmbH	Lantus	536	
351	7090450.00	None	Takeda Pharma GmbH	Edarbi	4380	
329	7049890.00	None	Guerbet GmbH	Dotarem	64	7
1249	5402500.00	Daiichi Sankyo Deutschland GmbH	CFC - Stolberg	Sevikar HCT	1436	
1333	4017745.20	Mundipharma gmbH	IfEG: Institut für Empirische Gesundheitsökonomie	Targin 10/20 Retard	133	
569	2352700.00	ALK-Abelló Arzneimittel GmbH	IAS Dr. Jörg Schnitker GmbH	Grazax, Avanz, ALK-depot SQ	4430	

Rough Top 10 final total fee by Firma

In [47]:
```
df_awb.groupby('Firma')['final_total_fee'].sum().sort_values(ascending=False).head(10)
```

Out[47]:
```
Firma
Abbott GmbH & Co. KG                                4984295.00
Roche Pharma AG                                     4573017.96
Sanofi-Aventis Deutschland GmbH                     3297441.75
AMGEN GmbH                                          2170981.22
Guerbet GmbH                                        1819630.00
Takeda Pharma GmbH                                  1164780.50
POI Pharm-Olam International Deutschland GmbH        790058.51
Chiltern International Ltd.                          689886.62
Medidata GmbH                                        590910.50
INC Research, vorher Kendle GmbH                     525560.00
Name: final_total_fee, dtype: float64
```

Analysis of fee comments

"Patient independent payments" and other interesting bits can be found.

In [35]:
```
pd.set_option('max_colwidth', 120)
v = ['Präparatname', 'Auftraggeber', 'Patienten geplant', 'Aufwandsentschädigung pro Patient', 'Aufwandsentschädigung gesamt in €']
abschluesse_df[abschluesse_df['Aufwandsentschädigung gesamt in €'].str.contains('unabh').fillna(False)][v]
```

Out[35]:

	Präparatname	Auftraggeber	Patienten geplant	Aufwandsentschädigung pro Patient	Aufwandsentschädigung gesamt in €
20	Lantus	NaN	1600	100	149.465 incl. 20 mal 75€ für Qualitätsüberprüfung (patientenunabhängig)
91	Revlimid, Velcade	Celgene International Sàrl	NaN	743.75	16.734,39 (inklusive patientenunabhängig 743,75€ pro Arzt)

In [36]:
```
df_all[df_all['Typ'] == 'Nahrungsergänzungsmittel'][v]
```

Out[36]:

	Präparatname	Auftraggeber	Patienten geplant	Aufwandsentschädigung pro Patient	Aufwandsentschädigung gesamt in €
12748	Cefamagar Tabletten	Cefak KG	350	150	None
13361	Cefamagar Tabletten	Cefak KG	494	150	None
13565	Cefamagar Tabletten	Cefak KG	494	150	None
13706	Cefamagar Tabletten	Cefak KG	493	150	None